

TEMPLATE PARA ENTREGA DO PROJETO DA DISCIPLINA
Projeto em Business Intelligence e Analytics
Fase 1

Nome do estudante: Eduarda Blanco

1 Introdução

Introduza o assunto, contextualizando, demonstrando a importância do tema a ser investigado e trabalhado. Apresente o desafio/problema, quais são as metas e como o documento foi estruturado.

A educação pública brasileira produz uma quantidade significativa de dados relacionados às escolas, matrículas, infraestrutura, rendimento e avaliações educacionais. Esses dados podem contribuir para a compreensão das condições de ensino e para o acompanhamento dos resultados alcançados pelas instituições. Entretanto, para que sejam efetivamente utilizados na tomada de decisão, é necessário organizá-los, integrá-los e transformá-los em informações de fácil interpretação. Nesse contexto, as soluções de Business Intelligence e Analytics possibilitam a construção de indicadores, a identificação de padrões e a geração de análises voltadas ao apoio da gestão educacional.

Entre os aspectos relacionados ao desempenho escolar, destaca-se a infraestrutura das instituições de ensino. Esse conceito não se limita à existência de prédios e salas de aula, abrangendo também serviços básicos, espaços pedagógicos, recursos tecnológicos, acessibilidade, equipamentos e condições adequadas de funcionamento. Por essa razão, a infraestrutura escolar deve ser analisada de maneira multidimensional, considerando diferentes elementos que compõem as condições de oferta da educação [AX18, AXdP19].

Estudos realizados no contexto educacional brasileiro indicam que as condições de infraestrutura podem estar associadas aos resultados obtidos pelas escolas. Recursos como acesso à internet, laboratórios, bibliotecas, quadras esportivas, equipamentos e ambientes adequados podem contribuir para o desenvolvimento das atividades pedagógicas. No entanto, o desempenho educacional é influenciado por diferentes fatores escolares, administrativos e contextuais, o que torna necessária uma análise integrada das informações disponíveis [SSdS20, VLRK21].

Diante desse cenário, este trabalho apresenta como problema de pesquisa a seguinte questão: quais fatores escolares estão associados às taxas de aprovação das escolas públicas de ensino fundamental de Porto Alegre, no período de 2018 a 2023? A escolha desse recorte busca analisar a realidade educacional do município por meio de dados públicos, considerando a evolução dos indicadores de rendimento e as características das instituições de ensino ao longo do período definido.

O objetivo geral do projeto é desenvolver uma solução de Business Intelligence e Analytics para analisar os fatores escolares associados às taxas de aprovação das escolas públicas de ensino fundamental de Porto Alegre. Para alcançar esse objetivo, pretende-se coletar, limpar, integrar e analisar dados educacionais públicos; definir indicadores estratégicos; construir visualizações para acompanhamento do desempenho escolar; investigar relações entre as características das escolas e seus resultados; e desenvolver uma análise preditiva para estimar a taxa de aprovação a partir dos dados históricos disponíveis.

Espera-se que a solução desenvolvida facilite a comparação entre escolas e períodos, permita identificar tendências e situações que demandem maior atenção e apresente informações relevantes para o apoio à gestão educacional. O projeto não pretende estabelecer relações de causa e efeito, mas identificar associações e padrões presentes nos dados analisados.

Além desta introdução, o documento apresenta o referencial teórico relacionado aos

principais conceitos utilizados no projeto, a revisão da literatura com estudos semelhantes, o plano de trabalho contendo o problema, as hipóteses, os objetivos, a metodologia, o cronograma e o desenho da solução, seguido das considerações finais e das referências utilizadas.

2 Referencial Teórico

Descreva aqui os principais fundamentos teóricos que auxiliam o leitor a compreender o tema do projeto.

Este capítulo apresenta os fundamentos teóricos necessários para a compreensão do projeto. São abordados os conceitos de Business Intelligence e Analytics, indicadores educacionais, desempenho escolar, infraestrutura escolar e fatores associados aos resultados educacionais. Também são discutidas as possibilidades e limitações do uso de dados públicos na análise da educação básica.

2.1 Business Intelligence e Analytics

Business Intelligence pode ser compreendido, no contexto deste projeto, como o conjunto de processos utilizados para coletar, organizar, integrar e apresentar dados com o objetivo de apoiar a tomada de decisão. Sua aplicação envolve a transformação de dados brutos em informações estruturadas, geralmente apresentadas por meio de indicadores, relatórios e dashboards.

Na área educacional, uma solução de Business Intelligence pode consolidar informações provenientes de diferentes fontes, permitindo acompanhar a evolução dos indicadores, realizar comparações entre escolas e identificar unidades que apresentam resultados distintos da média observada. Dessa forma, o BI será utilizado neste trabalho para organizar e apresentar dados históricos relacionados às características e ao rendimento das escolas públicas de ensino fundamental de Porto Alegre.

Analytics amplia essa abordagem ao empregar técnicas estatísticas e computacionais para identificar associações, padrões e tendências. Enquanto o componente de BI será direcionado principalmente à análise descritiva dos dados históricos, o componente de Analytics será utilizado para investigar os fatores associados à taxa de aprovação e desenvolver uma análise preditiva baseada nas características escolares disponíveis.

Neste trabalho, a solução será dividida em dois componentes complementares. O primeiro será responsável pela criação de indicadores e visualizações para o acompanhamento do desempenho educacional. O segundo será direcionado à análise das relações entre as variáveis e à estimativa da taxa de aprovação a partir dos dados históricos.

2.2 Indicadores educacionais e desempenho escolar

Os indicadores educacionais são medidas utilizadas para representar diferentes aspectos da realidade escolar. Eles permitem acompanhar condições de oferta, fluxo dos estudantes, recursos disponíveis e resultados alcançados pelas instituições de ensino. Entre os indicadores utilizados na educação básica estão as taxas de aprovação, reprovação e abandono, as matrículas, a média de alunos por turma e os resultados das avaliações educacionais.

O desempenho escolar pode ser analisado a partir de diferentes perspectivas. Uma delas considera o aprendizado demonstrado pelos estudantes em avaliações padronizadas, como

as realizadas pelo Sistema de Avaliação da Educação Básica. Outra perspectiva considera o fluxo escolar, representado por indicadores como aprovação, reprovação e abandono.

Neste projeto, a taxa de aprovação será adotada como principal variável de resultado. Esse indicador representa a proporção de estudantes que, ao final do período letivo, foram considerados aptos a avançar para a etapa seguinte. Entretanto, a taxa de aprovação não representa, isoladamente, todo o conceito de qualidade educacional, pois não mede diretamente a proficiência ou o aprendizado dos estudantes.

O Índice de Desenvolvimento da Educação Básica combina informações relacionadas ao fluxo escolar e ao desempenho em avaliações. Estudos que analisam o indicador demonstram que seus resultados podem estar associados a diferentes características das redes e das escolas, reforçando a necessidade de examinar múltiplas variáveis na interpretação do desempenho educacional [Cro21].

2.3 Infraestrutura escolar

A infraestrutura escolar compreende as condições físicas, os serviços, os equipamentos e os recursos disponíveis para o funcionamento das instituições de ensino. Esse conceito envolve aspectos como abastecimento de água, energia elétrica, saneamento, acessibilidade, salas de aula, bibliotecas, laboratórios, quadras esportivas, recursos tecnológicos e espaços destinados às atividades pedagógicas.

A infraestrutura não deve ser avaliada somente pela presença ou ausência de um único recurso. Trata-se de um construto complexo e multidimensional, que exige a utilização de diferentes indicadores para representar adequadamente as condições de oferta das escolas [AX18].

O modelo conceitual desenvolvido por [AXdP19] considera a infraestrutura como um componente da oferta educacional e, ao mesmo tempo, como um elemento que pode mediar os processos de ensino e aprendizagem. Os autores destacam que as fontes oficiais disponibilizam um volume significativo de informações sobre instalações, espaços e equipamentos, mas apresentam menor cobertura para aspectos relacionados ao bem-estar e à equidade.

Com base nessa perspectiva, a infraestrutura analisada neste projeto será organizada em diferentes dimensões. Serão considerados, conforme a disponibilidade dos dados, os serviços básicos, os espaços pedagógicos, os recursos tecnológicos, a acessibilidade, os equipamentos e as características gerais das instituições.

A abordagem multidimensional evita classificar uma escola como adequada somente porque ela possui determinado equipamento. Uma instituição pode, por exemplo, possuir acesso à internet, mas não apresentar biblioteca, laboratório, acessibilidade ou outros espaços necessários ao desenvolvimento das atividades educacionais.

2.4 Fatores associados ao desempenho escolar

O desempenho escolar é resultado de um conjunto de características que podem estar relacionadas aos estudantes, às famílias, às escolas, aos profissionais da educação e ao contexto social em que as instituições estão inseridas. Por esse motivo, sua análise não deve considerar a infraestrutura como o único fator relacionado aos resultados educacionais.

Estudos brasileiros identificaram associações entre determinadas condições de infraestrutura e o desempenho em avaliações educacionais. Entre os elementos analisados estão a presença de internet, laboratório de informática, quadra esportiva, acessibilidade, auditório e outros recursos escolares [SSdS20].

Também foram identificadas relações entre infraestrutura, investimentos públicos e indicadores educacionais. Esses resultados reforçam a importância de analisar conjuntamente as condições materiais das escolas e os resultados alcançados, sem assumir que a existência de determinado recurso produz, de forma isolada, uma melhoria no desempenho [VLRK21].

Além das condições físicas, fatores relacionados à prática docente, à adequação da formação dos professores e ao rendimento escolar também podem contribuir para explicar diferenças entre os resultados das instituições [GRNdMR21]. Entretanto, nem todas essas informações estarão necessariamente disponíveis na granularidade exigida pelo presente projeto.

Características familiares e sociodemográficas também podem estar associadas ao desempenho dos estudantes [eSFEL22]. Como o projeto utilizará predominantemente dados agregados por escola, algumas dessas dimensões não poderão ser observadas diretamente. Essa limitação deverá ser considerada na interpretação dos resultados.

Portanto, o termo “fatores associados” será utilizado para indicar a existência de relações estatísticas entre as características analisadas e a taxa de aprovação. A identificação de uma associação não será interpretada automaticamente como uma relação de causa e efeito.

2.5 Dados públicos aplicados à análise educacional

O desenvolvimento de análises educacionais em escala municipal depende da existência de dados públicos padronizados e identificáveis ao longo do tempo. Entre as principais fontes disponíveis estão o Censo Escolar, os indicadores educacionais e os resultados do Sistema de Avaliação da Educação Básica.

O Censo Escolar reúne informações relacionadas às escolas, turmas, matrículas, profissionais, equipamentos, instalações e serviços. Esses dados permitem caracterizar as instituições e construir indicadores sobre suas condições de funcionamento. O código de identificação da escola possibilita, conforme a compatibilidade entre os arquivos, a integração com outras bases educacionais.

Os dados públicos apresentam, entretanto, limitações de cobertura, preenchimento e comparabilidade. Alterações nos instrumentos de coleta, variáveis ausentes e diferenças entre os anos podem afetar a construção da série histórica. Além disso, nem todas as escolas possuem resultados divulgados nas avaliações educacionais.

O desenho e os critérios de participação do Saeb podem resultar na ausência de determinados estabelecimentos, especialmente escolas que não atendem aos requisitos definidos para divulgação dos resultados. Essa situação pode gerar uma visão incompleta da realidade e produzir vieses quando somente as escolas avaliadas são analisadas [BdM23].

Por essa razão, antes da modelagem dos indicadores e da análise preditiva, será necessário verificar a completude, a consistência e a compatibilidade dos dados entre os anos de 2019 e 2024. As limitações encontradas deverão ser documentadas e consideradas na interpretação dos resultados.

3 Revisão da Literatura

Descreva aqui os principais trabalhos correlatos, sejam eles ferramentas, abordagens ou técnicas relacionadas. Aqui é possível perceber o que vem sendo adotado para resolver o problema relacionado ao tema.

Este capítulo apresenta trabalhos relacionados à avaliação da infraestrutura escolar e à análise dos fatores associados ao desempenho educacional. Foram selecionados estudos publicados entre 2018 e 2023 que utilizam dados educacionais brasileiros, indicadores multidimensionais, técnicas estatísticas e métodos de mineração de dados. A análise desses trabalhos permite identificar as abordagens utilizadas, os resultados encontrados e as limitações que devem ser consideradas no desenvolvimento deste projeto.

3.1 Mensuração da infraestrutura escolar

Alves e Xavier [AX18] propuseram indicadores multidimensionais para avaliar a infraestrutura das escolas públicas brasileiras de ensino fundamental. O estudo buscou superar análises baseadas apenas na existência isolada de equipamentos ou dependências escolares. Para isso, os autores organizaram diferentes variáveis relacionadas às condições de funcionamento, aos espaços pedagógicos, aos recursos disponíveis e ao atendimento dos estudantes.

A principal contribuição do trabalho foi demonstrar que a infraestrutura escolar deve ser representada por um conjunto de dimensões e indicadores. Essa abordagem permite diferenciar escolas que possuem apenas condições elementares de funcionamento daquelas que dispõem de recursos mais adequados ao desenvolvimento das atividades educacionais. O estudo contribui para este projeto ao orientar a seleção e a organização das variáveis de infraestrutura presentes no Censo Escolar.

Posteriormente, Alves, Xavier e Paula [AXdP19] desenvolveram um modelo conceitual para avaliação da infraestrutura escolar no ensino fundamental. O trabalho foi fundamentado em marcos legais e em uma revisão de estudos nacionais e internacionais. A revisão identificou a inexistência de consenso sobre como definir e mensurar a infraestrutura escolar.

O modelo proposto pelos autores organizou a infraestrutura em seis dimensões: condições da área, condições de atendimento, condições básicas, condições pedagógicas, condições para o bem-estar e condições para a equidade. Ao todo, foram identificados 17 indicadores. Os autores também analisaram a disponibilidade dessas informações no Censo Escolar e no Sistema de Avaliação da Educação Básica.

O estudo apontou que as pesquisas oficiais possuem uma quantidade significativa de informações sobre instalações, espaços e equipamentos, mas apresentam menor cobertura para aspectos relacionados ao bem-estar e à equidade. Essa limitação é relevante para o presente projeto, pois a análise dependerá das variáveis efetivamente disponíveis nos dados públicos.

3.2 Infraestrutura e desempenho educacional

Soares, Soares e Santos [SSdS20] realizaram um estudo exploratório sobre as relações entre infraestrutura escolar e desempenho dos estudantes dos anos finais do ensino fundamental na Prova Brasil de 2017. Foram aplicadas técnicas de estatística descritiva e inferencial para analisar as condições das escolas brasileiras e verificar quais recursos apresentavam associação com o desempenho na avaliação.

Os resultados indicaram diferenças nas condições de infraestrutura entre as escolas e apontaram contribuições de fatores como laboratório de informática, acesso à internet, quadra esportiva, instalações acessíveis, coleta periódica de lixo e auditório. O estudo demonstra uma aplicação direta de análise de dados para relacionar características das instituições aos seus resultados educacionais.

Esse trabalho está diretamente relacionado ao projeto proposto, pois utiliza variáveis escolares como fatores explicativos do desempenho. Entretanto, enquanto o estudo utiliza os resultados da Prova Brasil de 2017 em escala nacional, o presente projeto utilizará dados históricos das escolas públicas de ensino fundamental de Porto Alegre e adotará a taxa de aprovação como principal variável de resultado.

Vasconcelos et al. [VLRK21] investigaram a relação entre infraestrutura escolar, investimentos públicos e desempenho educacional nos municípios brasileiros. Os autores utilizaram dados do Censo Escolar, do Índice de Desenvolvimento da Educação Básica e das despesas públicas em educação referentes aos anos de 2007 e 2017.

Como parte da metodologia, foi construído um Índice de Infraestrutura Escolar composto por quatro dimensões: serviços básicos, infraestrutura física, disponibilidade de equipamentos e capacitação de estudantes. As variáveis binárias receberam valor igual a um quando o recurso estava presente e zero quando estava ausente. Os subíndices das dimensões foram posteriormente agregados em um indicador geral.

Após a construção do índice, os autores aplicaram modelos de regressão quantílica para avaliar as relações entre infraestrutura, investimentos públicos e desempenho. Os resultados evidenciaram a importância das condições de infraestrutura e da capacidade administrativa dos municípios para o desempenho educacional.

A construção de um índice agregado é uma abordagem aplicável ao presente projeto. Em vez de analisar cada recurso de maneira completamente isolada, será possível criar categorias ou indicadores que representem diferentes dimensões da infraestrutura das escolas de Porto Alegre.

3.3 Análise de fatores associados ao desempenho

Garcia, Rios-Neto e Miranda-Ribeiro [GRNdMR21] analisaram fatores relacionados à qualidade do ensino médio brasileiro, considerando rendimento escolar, infraestrutura e prática docente. O estudo utilizou indicadores construídos a partir dos microdados do Censo Escolar e aplicou técnicas de mineração de dados para identificar os atributos mais relacionados aos resultados educacionais.

Embora o trabalho seja voltado ao ensino médio, sua abordagem é relevante por combinar dados escolares e técnicas analíticas para identificar padrões. O estudo também demonstra que a infraestrutura não deve ser observada isoladamente, pois características relacionadas aos

docentes e ao rendimento escolar podem contribuir para explicar diferenças nos resultados.

Crozatti [Cro21] investigou variáveis do contexto educacional associadas ao Ideb das redes públicas municipais de ensino fundamental do estado de São Paulo em 2017. O autor integrou informações provenientes de diferentes fontes oficiais e aplicou análises simples e multivariadas, incluindo regressão por mínimos quadrados ordinários.

Os resultados indicaram associações do Ideb com variáveis como gasto médio por aluno com pessoal próprio, esforço docente, abandono escolar e renda. Esse estudo demonstra a importância da integração de diferentes fontes e da análise conjunta de variáveis educacionais, administrativas e socioeconômicas.

A contribuição desse trabalho para o projeto está na utilização de dados públicos para identificar fatores associados a um indicador educacional. Entretanto, o estudo considera resultados agregados por rede municipal, enquanto o presente projeto pretende trabalhar, conforme a disponibilidade das bases, com dados na granularidade de escola e ano.

Silva et al. [eSFEL22] analisaram a associação entre recursos do ambiente familiar, características sociodemográficas e desempenho escolar de adolescentes do ensino fundamental. Foram consideradas informações sobre a interação entre família e escola, atividades realizadas com os responsáveis e recursos disponíveis no ambiente doméstico.

Os resultados apontaram que fatores externos à instituição também estão relacionados ao desempenho dos estudantes. Essa constatação é importante para evitar que os resultados do presente projeto sejam interpretados como consequência exclusiva da infraestrutura escolar.

Entretanto, as informações familiares analisadas por Silva et al. [eSFEL22] não estão disponíveis de forma equivalente no Censo Escolar. Dessa forma, essas variáveis não serão incluídas diretamente no modelo, constituindo uma limitação para a interpretação das associações identificadas.

3.4 Cobertura e limitações dos dados educacionais

Braga e Miranda [BdM23] investigaram como os critérios de participação no Saeb podem provocar a exclusão de determinadas escolas públicas de ensino fundamental das avaliações oficiais. A metodologia envolveu a exploração de dados do Censo Escolar e do Saeb de 2019, em conjunto com a literatura da área.

Os autores identificaram que muitas escolas não avaliadas estavam localizadas em áreas rurais, pertenciam às redes municipais e apresentavam condições menos favoráveis de infraestrutura e formação docente. Quando essas escolas não possuem resultados divulgados, sua situação pode deixar de ser adequadamente representada pelos indicadores utilizados nas políticas educacionais.

Essa discussão é relevante para o presente projeto porque nem todas as escolas de Porto Alegre poderão apresentar resultados do Saeb ou do Ideb em todos os anos. A exclusão automática das instituições sem esses indicadores pode produzir uma amostra que represente apenas as escolas com maior disponibilidade de dados.

Para reduzir esse problema, a análise utilizará prioritariamente as taxas de rendimento escolar, que possuem periodicidade anual, e tratará os resultados do Saeb e do Ideb como indicadores complementares. Também será necessário documentar a quantidade de escolas incluídas, excluídas e sem informações em cada etapa do processamento.

3.5 Síntese dos trabalhos relacionados

Os trabalhos analisados apresentam três abordagens principais. A primeira corresponde à construção de modelos e indicadores multidimensionais de infraestrutura escolar [AX18, AXdP19]. A segunda relaciona características escolares, investimentos, fatores administrativos e condições socioeconômicas aos resultados educacionais por meio de estatística, regressão e mineração de dados [SSdS20, VLRK21, GRNdMR21, Cro21]. A terceira discute fatores externos à escola e limitações das bases utilizadas nas avaliações educacionais [eS-FEL22, BdM23].

Os estudos demonstram que dados públicos, especialmente os provenientes do Censo Escolar, do Saeb e do Ideb, podem ser utilizados para caracterizar as instituições e investigar fatores associados ao desempenho. Também evidenciam que os resultados educacionais são multidimensionais e não devem ser explicados por uma única variável.

Entre os trabalhos selecionados, não foi identificado um estudo voltado especificamente às escolas públicas de ensino fundamental de Porto Alegre no período de 2019 a 2024 que integre uma solução de Business Intelligence, análise dos fatores escolares e modelagem preditiva da taxa de aprovação.

Dessa forma, o presente projeto diferencia-se por delimitar a análise ao município de Porto Alegre, organizar uma série histórica por escola, integrar indicadores de rendimento e infraestrutura, disponibilizar os resultados em dashboards e desenvolver uma análise preditiva. A proposta não busca substituir as abordagens dos trabalhos anteriores, mas aplicá-las em um recorte local e em uma solução integrada de Business Intelligence e Analytics.

4 Plano de Trabalho

4.1 Descrição do Problema

Os dados educacionais públicos disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, como o Censo Escolar e os Indicadores Educacionais, possibilitam acompanhar características das escolas, infraestrutura, matrículas e rendimento dos estudantes. Entretanto, esses dados são publicados em arquivos separados, possuem grande quantidade de variáveis e podem apresentar diferenças de estrutura entre os anos analisados.

A ausência de uma visão integrada dificulta a comparação do desempenho das escolas públicas de ensino fundamental de Porto Alegre e a identificação de características escolares que possam estar associadas às taxas de aprovação. Informações relacionadas a serviços básicos, espaços pedagógicos, acessibilidade, recursos tecnológicos e quantidade de alunos precisam ser organizadas e analisadas em conjunto com os indicadores de rendimento escolar.

Estudos anteriores indicam que a infraestrutura deve ser compreendida de maneira multidimensional e que diferentes características escolares podem apresentar associação com o desempenho educacional [AX18, AXdP19, SSdS20, VLRK21]. Entretanto, essas associações não devem ser interpretadas automaticamente como relações de causa e efeito, pois o desempenho também pode ser influenciado por fatores familiares, socioeconômicos, pedagógicos e administrativos que não estarão integralmente disponíveis nas bases utilizadas [eSFEL22].

O período de 2018 a 2023 inclui anos afetados pela pandemia de COVID-19, especialmente 2020 e 2021. Dessa forma, os resultados desses anos deverão ser analisados com cautela, considerando possíveis alterações no funcionamento das escolas, na avaliação dos estudantes e nos indicadores de aprovação.

Diante desse contexto, este projeto pretende integrar dados educacionais públicos, construir indicadores de negócio, disponibilizar visualizações e desenvolver uma análise preditiva da taxa de aprovação.

Assim, busca-se responder à seguinte pergunta de pesquisa:

Quais fatores escolares estão associados às taxas de aprovação das escolas públicas de ensino fundamental de Porto Alegre entre 2018 e 2023, e em que medida esses fatores permitem estimar o indicador de aprovação?

4.2 Hipóteses

Com base nos trabalhos analisados, foram formuladas as seguintes hipóteses:

1. Escolas com melhores condições gerais de infraestrutura apresentam maiores taxas de aprovação.
2. A disponibilidade de recursos pedagógicos e tecnológicos, como biblioteca ou sala de leitura, acesso à internet, computadores e laboratório de informática, está associada positivamente à taxa de aprovação.
3. Escolas com melhores condições de acessibilidade e serviços básicos apresentam maiores taxas de aprovação.

4. Uma maior quantidade média de estudantes por turma está associada a menores taxas de aprovação.
5. Existem diferenças nas taxas de aprovação entre escolas municipais e estaduais de Porto Alegre.
6. Um modelo preditivo construído com características de infraestrutura, porte, organização escolar, dependência administrativa e período analisado é capaz de estimar a taxa de aprovação com desempenho superior a um modelo de referência baseado apenas na média histórica.

As hipóteses serão avaliadas conforme a disponibilidade, a completude e a qualidade das variáveis presentes nas bases públicas. A ausência de evidências suficientes poderá resultar na rejeição ou na impossibilidade de confirmação de uma hipótese.

4.3 Objetivos

4.3.1 Objetivo Geral

Desenvolver uma solução de Business Intelligence e Analytics para analisar os fatores escolares associados às taxas de aprovação das escolas públicas de ensino fundamental de Porto Alegre entre 2018 e 2023.

4.3.2 Objetivos Específicos

1. Coletar dados públicos relacionados às escolas, à infraestrutura, às matrículas e ao rendimento escolar.
2. Filtrar as escolas públicas de ensino fundamental localizadas em Porto Alegre.
3. Avaliar a qualidade, a completude e a compatibilidade dos dados entre os anos de 2018 e 2023.
4. Limpar, padronizar e integrar as bases por meio do código da escola e do ano de referência.
5. Construir indicadores relacionados à aprovação, reprovação, abandono, matrículas, porte e infraestrutura escolar.
6. Analisar a evolução das taxas de rendimento ao longo do período estudado.
7. Comparar os resultados entre escolas, anos e dependências administrativas.
8. Investigar associações entre características escolares e taxas de aprovação.
9. Desenvolver dashboards para apresentação dos indicadores educacionais.
10. Construir e avaliar um modelo preditivo para estimar a taxa de aprovação das escolas.
11. Disponibilizar os códigos, a documentação e os resultados do projeto em um repositório no GitHub.

4.4 Atividades e Cronograma

O desenvolvimento do projeto será realizado entre 27 de julho e 8 de setembro de 2026. As atividades previstas são:

1. Definição do problema, delimitação, hipóteses e objetivos.
2. Pesquisa e análise dos trabalhos relacionados.
3. Identificação e coleta das bases educacionais.
4. Compreensão, seleção e descrição das variáveis.
5. Limpeza, padronização e tratamento dos dados.
6. Integração das bases e construção da base analítica.
7. Análise exploratória e definição dos indicadores.
8. Desenvolvimento dos dashboards de Business Intelligence.
9. Desenvolvimento e avaliação do modelo preditivo.
10. Documentação do código e organização do repositório no GitHub.
11. Elaboração do relatório e da apresentação executiva.
12. Revisão, validação e entrega final do projeto.

Tabela 4.1: Cronograma de atividades do projeto em 2026.

Atividade	Julho	Agosto	Setembro
1. Definição do projeto	X		
2. Pesquisa bibliográfica	X	X	
3. Identificação e coleta das bases		X	
4. Seleção e descrição das variáveis		X	
5. Limpeza e padronização dos dados		X	
6. Integração e construção da base analítica		X	
7. Análise exploratória e definição dos indicadores		X	
8. Desenvolvimento dos dashboards		X	X
9. Modelagem e avaliação preditiva		X	X
10. Documentação e organização do GitHub		X	X
11. Elaboração do relatório e da apresentação executiva		X	X
12. Revisão e entrega final			X

4.5 Metodologia

A pesquisa será de natureza aplicada, pois pretende desenvolver uma solução de Business Intelligence e Analytics para um problema relacionado à análise da educação pública. A abordagem será quantitativa, baseada no processamento e na análise de dados educacionais estruturados.

Quanto aos objetivos, a pesquisa será exploratória e descritiva. A etapa exploratória será utilizada para compreender as bases, verificar a qualidade dos dados e identificar possíveis padrões. A etapa descritiva será empregada para caracterizar as escolas e apresentar a evolução dos indicadores entre 2018 e 2023.

A unidade de análise será composta por cada combinação entre escola e ano. Dessa forma, um mesmo estabelecimento poderá possuir até seis registros, correspondentes aos anos de 2018, 2019, 2020, 2021, 2022 e 2023.

4.5.1 Fontes de Dados

Serão utilizados dados secundários e públicos disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. As principais fontes previstas são:

1. Microdados do Censo Escolar;
2. Indicadores de Taxas de Rendimento Escolar;
3. Indicadores de Média de Alunos por Turma;
4. Resultados do Ideb e do Saeb, quando disponíveis e compatíveis com a granularidade da análise.

Os resultados do Ideb e do Saeb serão utilizados como informações complementares, pois não possuem periodicidade anual e podem não estar disponíveis para todas as escolas. A taxa de aprovação será a principal variável de resultado do projeto.

4.5.2 Critérios de Inclusão e Exclusão

Serão incluídos os registros que atendam aos seguintes critérios:

1. escolas localizadas no município de Porto Alegre;
2. escolas pertencentes à rede pública;
3. instituições que ofertem alguma etapa do ensino fundamental;
4. registros referentes ao período entre 2018 e 2023;
5. registros com código de escola válido;
6. registros com taxa de aprovação disponível para a análise principal.

Serão excluídas escolas privadas, instituições localizadas fora de Porto Alegre, registros duplicados, registros sem identificação válida e informações que não possam ser compatibilizadas entre as bases.

A quantidade de registros incluídos e excluídos será documentada para evitar que a análise esconda perdas significativas de dados.

4.5.3 Aplicação do CRISP-DM

A execução do projeto seguirá as fases do CRISP-DM:

1. **Compreensão do problema:** definição do problema de pesquisa, das necessidades de análise, dos objetivos, das hipóteses e dos indicadores.
2. **Compreensão dos dados:** coleta das bases, análise dos dicionários, descrição das variáveis, avaliação da granularidade e identificação de problemas de qualidade.
3. **Preparação dos dados:** filtragem de Porto Alegre, seleção das escolas públicas de ensino fundamental, padronização das colunas, tratamento de valores ausentes, remoção de duplicidades e integração das bases.
4. **Modelagem:** construção dos indicadores, análise das associações e treinamento dos modelos preditivos.
5. **Avaliação:** comparação dos modelos, análise das métricas, verificação das hipóteses e avaliação da coerência dos resultados com o problema proposto.
6. **Implantação:** publicação dos dashboards, organização do repositório, documentação dos códigos e apresentação dos resultados.

4.5.4 Preparação e Qualidade dos Dados

O processamento será desenvolvido no Google Colab com a linguagem Python. Serão utilizadas principalmente as bibliotecas Pandas e NumPy para manipulação dos dados, Matplotlib e Plotly para exploração e visualização e Scikit-learn para modelagem preditiva.

Durante a preparação, serão realizadas as seguintes verificações:

1. existência de valores ausentes;
2. duplicidade de registros;
3. compatibilidade dos códigos das escolas;
4. alterações nos nomes e tipos das colunas entre os anos;
5. presença de valores inválidos ou fora dos limites esperados;
6. quantidade de escolas disponíveis em cada ano;
7. mudanças relevantes nas variáveis ao longo da série histórica.

As variáveis de infraestrutura serão agrupadas, conforme sua disponibilidade, em dimensões como serviços básicos, espaços pedagógicos, recursos tecnológicos, acessibilidade e equipamentos. Poderá ser construído um indicador consolidado de infraestrutura, seguindo a abordagem multidimensional discutida por [AX18, AXdP19].

4.5.5 Business Intelligence

A solução de Business Intelligence será desenvolvida no Power BI a partir da base tratada no Google Colab. O modelo de dados terá como principais dimensões escola, ano, localização e dependência administrativa, além das tabelas de indicadores de rendimento e infraestrutura.

Entre os indicadores previstos estão:

1. taxa média de aprovação;
2. taxa média de reprovação;
3. taxa média de abandono;
4. quantidade de escolas analisadas;
5. quantidade de matrículas;
6. média de estudantes por turma;
7. variação anual da taxa de aprovação;
8. percentual de escolas acima ou abaixo da média municipal;
9. indicadores de disponibilidade de infraestrutura;
10. comparação entre redes municipal e estadual.

Os dashboards permitirão aplicar filtros por escola, ano, dependência administrativa e outros atributos disponíveis.

4.5.6 Analytics e Modelagem Preditiva

A etapa de Analytics será desenvolvida no Google Colab. Inicialmente, serão aplicadas estatísticas descritivas e análises gráficas para examinar distribuições, tendências, valores discrepantes e relações entre as variáveis.

A taxa de aprovação será utilizada como variável dependente. As características de infraestrutura, matrículas, média de estudantes por turma, dependência administrativa e ano serão avaliadas como possíveis variáveis explicativas.

Como a variável de resultado é numérica, serão testados modelos de regressão, como:

1. regressão linear;
2. árvore de decisão para regressão;

3. Random Forest para regressão.

Os dados de 2018 a 2022 serão utilizados para treinamento e os dados de 2023 serão reservados para teste. Essa divisão permitirá avaliar o desempenho do modelo em um período não utilizado durante o treinamento.

Os modelos serão comparados por meio das métricas de Erro Médio Absoluto, Raiz do Erro Quadrático Médio e coeficiente de determinação. Também será utilizado um modelo de referência baseado na média histórica para verificar se os algoritmos apresentam ganho real de desempenho.

A interpretação dos resultados será limitada à identificação de associações e capacidade preditiva. Não serão estabelecidas relações de causalidade entre infraestrutura e aprovação.

4.5.7 Documentação e Reprodutibilidade

Os códigos de coleta, tratamento, integração, análise e modelagem serão armazenados em um repositório no GitHub. O repositório deverá conter:

1. arquivo de apresentação do projeto;
2. descrição das fontes de dados;
3. instruções para execução dos códigos;
4. notebooks do Google Colab;
5. dicionário das variáveis selecionadas;
6. arquivos de dados tratados, quando permitido pelas fontes;
7. descrição dos indicadores e métricas;
8. resultados da avaliação dos modelos;
9. link para os dashboards publicados.

Essa organização permitirá documentar as decisões tomadas e facilitar a reprodução das etapas do projeto.

4.6 Desenho da Solução

A solução proposta contempla as etapas de coleta, preparação, integração, análise, visualização e modelagem preditiva dos dados educacionais, conforme apresentado na Figura 4.1.




Figura 4.1: Desenho da solução proposta

5 Conclusão

Conclua o seu trabalho, apresente os principais destaques e depois analise suas hipóteses e objetivos. Ao final, sugira trabalhos futuros.

Este trabalho apresentou o planejamento de uma solução de Business Intelligence e Analytics destinada à análise dos fatores escolares associados às taxas de aprovação das escolas públicas de ensino fundamental de Porto Alegre, considerando o período de 2018 a 2023. A proposta parte da necessidade de transformar dados educacionais públicos, disponibilizados em diferentes arquivos e estruturas, em informações integradas e úteis para a compreensão do desempenho escolar.

Entre os principais aspectos abordados estão a definição do problema de pesquisa, a formulação das hipóteses, o estabelecimento dos objetivos, a identificação das fontes de dados, a escolha das ferramentas e a organização das atividades necessárias para a execução do projeto. Também foi elaborado o desenho da solução, contemplando coleta, preparação, integração, análise dos dados, construção de indicadores, desenvolvimento de dashboards e aplicação de modelos preditivos.

A pesquisa se justifica pela relevância do acompanhamento dos indicadores educacionais e pela necessidade de compreender como características de infraestrutura, porte, organização e dependência administrativa podem estar associadas aos resultados das escolas. Os estudos analisados demonstram que a infraestrutura escolar deve ser compreendida de maneira multidimensional e que o desempenho educacional não pode ser explicado por uma única variável. Dessa forma, o projeto busca oferecer uma análise integrada, sem atribuir relações de causalidade a partir de associações estatísticas.

As hipóteses propostas ainda não podem ser confirmadas ou rejeitadas, pois esta etapa corresponde ao planejamento da pesquisa. A avaliação dessas hipóteses dependerá da coleta, da qualidade, da compatibilidade e da análise dos dados referentes ao período selecionado. Da mesma forma, o objetivo geral somente será integralmente alcançado após a implementação da solução de Business Intelligence e Analytics na segunda fase do projeto.

Como contribuição esperada, pretende-se avançar na compreensão da realidade educacional de Porto Alegre por meio de um recorte local e histórico, integrando indicadores de rendimento e características escolares em uma única solução analítica. A disponibilização de dashboards e análises preditivas poderá facilitar a identificação de padrões, diferenças entre escolas e situações que demandem maior atenção da gestão educacional.

Como trabalhos futuros, prevê-se a execução do processo de coleta e preparação das bases, a construção dos indicadores, o desenvolvimento dos dashboards no Power BI e a aplicação de modelos de regressão no Google Colab. Também poderão ser incorporados resultados do Ideb e do Saeb, dados socioeconômicos e informações territoriais, desde que apresentem disponibilidade e compatibilidade com a granularidade definida.

Por fim, espera-se que o projeto contribua para demonstrar como técnicas de Business Intelligence e Analytics podem ser aplicadas aos dados públicos educacionais, transformando registros dispersos em informações capazes de apoiar análises, planejamento e tomada de decisão.

Referências Bibliográficas

- [AX18] Alves, M. T. G.; Xavier, F. P. “Indicadores multidimensionais para avaliação da infraestrutura escolar: o ensino fundamental”, *Cadernos de Pesquisa*, 48–169, 2018, 708–746.
- [AXdP19] Alves, M. T. G.; Xavier, F. P.; de Paula, T. S. “Modelo conceitual para avaliação da infraestrutura escolar no ensino fundamental”, *Revista Brasileira de Estudos Pedagógicos*, 100–255, 2019, 297–330.
- [BdM23] Braga, D. S.; de Miranda, C. C. “Escolas invisibilizadas: desigualdades nas condições de oferta e limites dos instrumentos de políticas públicas”, *Ensaio: Avaliação e Políticas Públicas em Educação*, 31–120, 2023, 630–651.
- [Cro21] Crozatti, J. “Variáveis que influenciaram o IDEB do ensino fundamental das redes públicas municipais paulistas em 2017”, *Educação e Pesquisa*, 47, 2021, e230327.
- [eSFEL22] e Silva, R. M. C.; Fernandes, G. N. A.; Escarce, A. G.; Lemos, S. M. A. “Recursos do ambiente familiar e desempenho escolar: análise de fatores associados em adolescentes do ensino fundamental”, *CoDAS*, 34–2, 2022, e20210058.
- [GRNdMR21] Garcia, R. A.; Rios-Neto, E. L. G.; de Miranda-Ribeiro, A. “Efeitos rendimento escolar, infraestrutura e prática docente na qualidade do ensino médio no Brasil”, *Revista Brasileira de Estudos de População*, 38, 2021, 1–32.
- [SSdS20] Soares, D. J. M.; Soares, T. E. A.; dos Santos, W. “Infraestrutura e desempenho escolar na Prova Brasil: aspectos e conexões”, *Olhar de Professor*, 23, 2020, 1–18.
- [VLRK21] Vasconcelos, J. C.; Lima, P. V. P. S.; Rocha, L. A.; Khan, A. S. “Infraestrutura escolar e investimentos públicos em Educação no Brasil: a importância para o desempenho educacional”, *Ensaio: Avaliação e Políticas Públicas em Educação*, 29–113, 2021, 874–898.